

SimHash: Schnelle Detektion von Plagiaten

Dominic van der Zypen

2026-09-07

Was ist eine Hash-Funktion?

- ▶ Fixe Output-Bitlänge $n \in \mathbb{N}$.
- ▶ Ein **Hash** ist eine Funktion

$$h : \{0, 1\}^* \rightarrow \{0, 1\}^n.$$

- ▶ Beispiele:
 1. Initialen bei Namen.
 2. "Parity bit" + Verallgemeinerungen.
- ▶ Gewünschte Eigenschaft: **Avalanche effect**, d.h. kleine Änderungen im Input geben grosse Änderungen im Output.

Beispiel für einen SimHash-Fingerprint

Input: "Hallo Welt!" | Anzahl Zeichen: 11 | Anzahl Trigramme: 9 | Mehrheit: ≥ 5

Trigramm	32-bit-Hash (binär)	Hexadezimal
"Hal"	1010 1001 0111 0101 0000 1111 1001 0110	0xa9750f96
"all"	1010 1001 0000 1010 1100 1111 1000 0011	0xa90acf83
"llo"	0011 0111 1110 0010 1101 1000 0100 0001	0x37e2d841
"lo "	1100 1111 1111 0001 0011 1101 1110 0111	0xcff13de7
"o W"	1100 1101 0011 1011 0111 0100 0101 1111	0xcd3b745f
" We"	1011 0010 0001 0011 0010 1010 1010 0011	0xb2132aa3
"Wel"	0000 1101 0001 1111 1101 0000 0111 1010	0x0d1fd07a
"elt"	1111 1001 1010 1111 1010 0011 0001 1011	0xf9afa31b
"lt!"	1001 0101 0100 0101 0110 1110 1110 1111	0x95456eef
1-Count	[7, 8, 4, 4, 4, 4, 5, 5, 4, 5, 5, 6, 4, 5, 5, 4, ...]	
Fingerprint	1010 1101 0011 0011 0110 1110 1100 0011	0xad336ec3

Regel: Für jede Bit-Position j gibt es eine "Abstimmung": Der Fingerprint ist 1, falls $\text{voting_vector}[j] \geq 5$, und 0 sonst.

Ähnlichkeitsvergleich via Hamming-Distanz

- Die **Hamming-Distanz** $d_H(x, y)$ zählt die Anzahl abweichender Bits:

$$d_H(x, y) = \text{popcount}(x \oplus y)$$

- Kein Avalanche effect bei SimHash:

Ähnliche Dokumente $\Rightarrow$ kleine Hamming-Distanz.

Dokument	SimHash Fingerprint (32-Bit)	Hex
Text A ("Hallo Welt!")	1010 1101 0011 0011 0110 1110 1100 0011	0xad336ec3
Text B ("Hallo Welt.")	1010 1101 0011 0011 0110 1110 110 1 00 0 1	0xad336ed1
Bit-Vergleich	0000 0000 0000 0000 0000 0000 000 1 00 1 0	2 Bits Diff

Fazit: Da $d_H(A, B) = 2 \leq k$ (typischer Schwellenwert $k \approx 3$), werden die Dokumente als **ähnlich / Plagiat** eingestuft.